

DR.Experts: 用于盲图像质量评估的失真感知专家的差分细化


Bohan Fu, Guanyi Qin, Fazhan Zhang, Zihao Huang, Mingxuan Li, Runze Hu,

¹ 北京理工大学, 北京 100086, 中国

新加坡国立大学,²新加坡 119276, 新加坡 {fubohan809, zfz63622, huangzihhhh, limx1630, hrzlpk2015}@gmail.com, guanyi.qin@u.nus.edu

摘要

盲图像质量评估旨在无参考地复制人类对视觉质量的感知，在视觉任务中发挥着关键作用，然而现有模型往往无法有效捕捉细微的失真线索，导致与人类主观判断出现偏差。我们识别出这一局限性的根本原因在于缺乏可靠的失真先验，因为方法通常学习统一图像特征与质量分数之间的浅层关系，导致其对失真不敏感，从而限制了其性能。为解决这一问题，我们引入 DR.Experts，这是一个新颖的先验驱动型 BIQA 框架，旨在明确地结合失真先验，实现可靠的质量评估。DR.Experts 首先利用一个感知失真的视觉语言模型获取特定于失真的先验，这些先验通过提出的失真显著性微分模块进一步精炼和增强，通过将它们与语义注意力区分开来，从而确保失真的真实表示。优化的先验知识，连同语义和桥接表示，随后通过一个名为动态失真加权模块的专家混合风格模块进行融合。该机制根据每个失真特定特征的感知影响进行加权，确保最终的质量预测与人类感知一致。在五个具有挑战性的 BIQA 基准上进行的广泛实验表明，DR.Experts 优于当前方法，并展示了其在泛化能力和数据效率方面的卓越性能。



代码 — <https://github.com/FuBohan01/DR.Experts>

引言

高质量图像对于视觉任务中的可靠性能至关重要。作为具有指导意义且在现实世界质量控制中起着关键和有价值作用的组成部分，盲图像质量评估（BIQA）旨在无需参考图像即可评估图像视觉质量，从而减轻在自然场景中难以获取参考的负担（Huang 等人，2024；Li 等人，2025；Mittal、Moorthy 和 Bovik，2012）。尽管已经做出了大量努力来推动 BIQA 的边界，但优势

图 1: (a): DR.Experts 即使在有限的训练数据下仍保持优势。(b): 对于一张失真图像, 提出的 DR.Experts 框架首先利用专门针对视觉失真的视觉语言模型获取对应各种失真的注意力。通过这些线索与语义注意力区分开来, DR.Experts 有效地进一步纯化失真感知表示。这些精炼的特征然后根据其感知重要性进行自适应加权并整合, 以产生精确且感知一致的图像质量评估。

同等贡献，+通讯作者。

版权所有 © 2026, 人工智能促进协会 (www.aaai.org)。保留所有权利。

仍然缺乏参考图像的情况仍然会引入显著的性能挑战，特别是在失真建模方面（Moorthy 和 Bovik 2011）。现有的 BIQA 技术

仍然难以有效地表征质量感知表示，削弱了它们与人类对感知质量评价的一致性。

此类限制的主要原因在于，由于缺乏失真先验的指导，它们对细微失真以及复杂多样失真下的概念模糊性敏感性降低。虽然盲图像质量评估（BIQA）通过近期复杂学习架构的开发和先进训练策略取得了显著进展（Chen 等人，2024），但这些方法（Yang 等人，2024）仍然专注于学习整合统一图像特征与最终质量分数之间的简单关系。然而，自然场景中的图像常常遭受不同类型和不同程度失真（Hosu 等人，2020）的影响，如曝光不足、噪声和运动模糊，这些失真以不同方式和程度影响图像视觉质量。然而，现有 BIQA 数据集数量有限，加上缺乏失真规范和标注，限制了模型学习和准确捕捉这些微妙但重要的失真相关特征的能力。

随着捕捉失真特定特征所面临的挑战凸显了现有 BIQA 方法中的根本性差距，因此，自然而然地，推进 BIQA 的一个关键动机是有效地将失真先验知识融入当前的学习框架（Li 等人，2024a），从而实现对质量感知表示进行细粒度和感知对齐的建模。基于这一见解，我们提出了一种名为 DR.Experts 的失真感知专家差异细化 BIQA 框架，该框架结合失真先验知识来指导提取与感知视觉质量相关的特征，并通过与语义特征的区分来进一步蒸馏和纯化这些特征。这些细化后的特征根据它们对图像质量各自贡献的不同，以自适应的权重进行聚合，充当不同失真视角的多重专家，从而生成全面且值得信赖的质量预测，如图 1 所示。这样的设计不仅增强了预测与人类感知的一致性，还提供了决策过程的透明度，因为生成的分数可以追溯到特定的失真因素，从而提高了评估的可信度。

为此，CLIP（Radford 等人，2021 年）被整合到所提出的框架中用于失真先验。作为视觉和文本之间的基础，对比语言-图像预训练（CLIP）通过将两种模态映射到共享的嵌入空间，实现可迁移的先验，其中文本可以提示与失真相关的视觉特征。具体来说，我们采用了 DA-CLIP（Luo 等人，2024 年），这是一种针对低级视觉任务优化的衍生版本，并经过微调以增加对失真特征的敏感性。DA-CLIP 在涉及十种不同失真类型（包括模糊、低光和压缩错误）的任务中展示了强大的细粒度失真感知能力，平均准确率达到了 99.2%。基于这一点

我们通过文本编码器提取的提示表示与图像编码器提取的视觉特征之间的点积，获得了 DA-CLIP 在各种特定失真提示下激活的失真感知视觉注意力作为先验。为了进一步增强这些表示并抑制来自 CLIP 和视觉 Transformer（ViT）的上游分类预训练产生的语义冗余注意力噪声（Dosovitskiy 等人，2020），我们引入了失真显著性微分模块（DSDM），其具有微分细化注意力机制以隔离与失真相关的特征。DSDM 通过对比 DA-CLIP 的失真感知注意力与 ViT 提取的语义注意力来细化先验，从而确保精确的质量评估。

此外，为了有效集成和利用不同类型的特征，并考虑到各种失真以不同方式和程度影响感知质量，我们设计了动态失真加权模块（DDWM），这是一种专家混合（MoE）架构，能够自适应地聚合这些特征组：由 DSDM 精细化的失真先验、由 ViT 提取的语义特征，以及作为中间补充的桥接特征，这些特征由上述两个特征组之间的差异导出。该模块不仅对多种表示形式之间的互补线索进行建模，还允许根据不同失真类型的感知影响分配自适应权重。通过这种方式，我们提出的方法框架更紧密地符合人类视觉系统的细粒度评估标准，进一步提高了生成质量分数的准确性和可信度。总而言之，我们的贡献可以概括如下：

- 我们提出了一种利用失真先验作为指导的新型 BIQA 框架，实现细粒度、失真感知的质量评估。通过利用 DACLIP 的文本提示可迁移视觉注意力作为先验，我们的框架学习生成可信且可解释的结果。该框架增强了人类感知失真表征与质量指标之间的感知一致性。
- 引入了一种名为失真显著性差异模块（Distortion-Saliency Differential Module）的新模块，通过区分 DA-CLIP 的失真感知注意力和 ViT 衍生的语义注意力来细化失真先验。DSDM 有效抑制了预训练中冗余的语义噪声，同时增强了失真特征的显著性。
- 进一步提出了动态失真加权模块，用于动态地为得分标记分配不同类型和级别的失真显著性权重，旨在模拟专家根据失真特征进行主题质量评估的综合分析。
- 我们在五个多样化且具有挑战性的 BIQA 基准上验证了所提出的框架，其中它始终优于其他竞争对手，并展示了强大的泛化能力和数据效率。

相关工作

盲图像质量评估

传统的 BIQA 方法主要使用基于自然场景统计的手工特征（Zhang, Zhang, and

张博维克 2015 年；王等人 2021 年；萨德、博维克和夏里尔 2012 年)。然而，由于手动特征选择导致的受限表示，这些方法在自然场景中表现出有限的泛化能力。随着深度学习的发展，BIQA 取得了显著改进。当前基于学习的方法可以分为基于 CNN 和基于 ViT 的方法 (朱等人 2025b)，这些方法提取图像特征，用于直接端到端的评分回归 (张等人 2020 年；康等人 2014 年；博斯等人 2017 年)。通过增加模型容量和深度，例如在大型数据集 (邓等人 2009 年) 上预训练的 ResNet (何等人 2016 年) 和 ViT (多索夫基等人 2020 年)，被用于进一步感知图像失真 (沈、李和金 2024 年；徐等人 2023 年)。为了克服 IQA 数据集的有限规模，一些自监督学习方法在失真模型形成的退化图像上进行对比学习 (阿格诺卢奇等人 2024a 年；萨哈、米什拉和博维克 2023 年)，以全面感知失真的差异和相似性。与此同时，领域自适应、多尺度特征自适应等技术 (Chu 等人, 2025a；Hu 等人, 2025；Qin 等人, 2025) 也被探索用于推进 BIQA (Su 等人, 2020)。最近，多模态大语言模型被广泛应用于下游视觉任务 (Wu 等人, 2024b；Li 等人, 2023)，研究人员也通过微调探索它们在 BIQA 上的强大视觉理解和感知能力。因此，以促进盲图像质量评估研究的可解释性和鲁棒性 (Zhou 等人)。

2025; 吴等人 2024a).

用于低级视觉的 CLIP

基于大规模 (图像、文本) 对和对比预训练的基础，CLIPs (Radford 等人 2021)，一系列模型，在迁移学习和下游视觉任务中展现出强大的零样本能力，因此被广泛应用于下游视觉任务 (Agnolucci 等人 2024b；Liang 等人 2023)。CLIP-IQA 作为首项工作，通过精心设计的提示序列探索了使用 CLIP 进行 BIQA 的可能性 (Wang、Chan 和 Loy 2023)。同时，多任务学习和自监督策略等方法被进一步采用，以利用 CLIP 在 BIQA 领域的知识。(Agnolucci、Galteri 和 Bertini 2024；Kwon 等人 2024)。DACLIP 通过引入控制器来适应低级视觉任务，准确预测输入图像的失真类型，取得了 99.2 的准确率 (Luo 等人 2024)。在本文中，我们利用 DA-CLIP 获得的特定失真类型的先验知识，指导我们提出的模型以细粒度的方式评估图像质量。

方法论

概述

在这项工作中，我们提出了一种新的 BIQA 网络，该网络在图像中特定类型失真的先验指导下精确评估图像，形成专家混合体。整体框架如图 2 所示。具体而言，使用 RGB 图像作为输入，并采用视觉 Transformer 作为图像编码器。同时，

使用 DA-CLIP 来识别图像中存在的失真类型。随后，我们引入了失真显著性差分模块，通过去除与失真特征无关的噪声来细化不同的图像失真信息，并增强失真特征的显著性。为了避免图像中非主导或缺失的失真类型对最终质量评估的影响，我们设计了动态失真加权模块，以整合来自图像编码器的语义特征、由 DSDM 精炼的失真先验以及它们之间差异推导出的补充区间特征。由上述三种特征形成的综合特征组为不同失真类型的专家分配动态权重，并获取最终图像质量分数。

失真特定先验

在大多数先前工作中，人们严重依赖数据驱动方法。然而，我们引入了失真类型的先验知识，使模型能够更有针对性地提取特征，从而减少对数据驱动方法的过度依赖。在这项工作中，我们采用 DA-CLIP 作为失真特定先验模块。基于冻结的 CLIP 文本和图像编码器，DA-CLIP 通过对比学习训练一个额外的图像控制器，以预测高质量图像失真特征嵌入。CLIP 是一个多模态模型，它将图像和文本对齐到共享的嵌入空间中，广泛应用于跨模态检索和理解任务。DA-CLIP 旨在生成与输入图像实际失真类型相匹配的特征，使其更适合退化场景的需求。具体来说，我们使用 DACLIP 的图像失真类型特征嵌入作为图像质量评估任务的先验知识。DACLIP 通过图像控制器 E 和文本编码器 E，将输入的 RGB 图像 $I \in \mathbb{R}$ 映射到相同的特征空间，并映射到十个预定义的常见图像失真类型 $T = [\text{运动模糊}, \text{雾天}, \text{JPEG 压缩}, \text{暗光}, \text{噪声}, \text{雨滴}, \text{雨天}, \text{阴影}, \text{雪天}, \text{未完成}]$ 中。具体来说，退化图像表示形式为 $E = E(I)$ ，而第 i 种失真类型的文本表示形式为 $E = E(T)$ 。我们使用类似于 CLIP-IQA (Wang, Chan, and Loy 2023) 的 Hadamard 积来获得不同失真类别下图像的表示。这个过程可以表示为：

$$F = \text{Linear} \quad E \odot E \quad \boxtimes \quad . \tag{1}$$

失真显著性差异模块

受差分 Transformer (Ye 等人, 2025 年) 的启发，该模型通过差分机制有效抑制了同质注意力中的噪声，我们将这种方法扩展到异质注意力，并提出了差分细化注意力机制。该机制能够抑制失真先验知识与图像编码器语义信息之间的冗余或重叠信息，包括注意力噪声和某些高级语义信息。此外，它




图 2: DR.Experts 的整体架构。我们利用 DA-CLIP 获取先验知识，并使用 DSDM 进行注意力细化。DDWM 随后作为专家，对失真的重要性进行加权，并给出最终预测。

增强了与失真相关的先验知识。具体来说，RGB 图像通过视觉 Transformer 处理以提取高级语义特征 $F \in \mathbb{R}^N$ ，其中 N 是序列长度， E 是嵌入维度。同时，RGB 图像 I 通过 DA-CLIP 处理以获得特征 $F \in \mathbb{R}^N$ ，其中 $i \in [1, 2, \dots, 10]$ ，对应于特定的失真类型。F 被提出作为 DA-CLIP 中的退化类别信息查询，旨在从图像控制器生成的图像特征 E 中提取与特定失真类型相关的特征。在这个阶段，失真特征包含少量语义信息和注意力噪声。图像编码器提取的语义特征的查询和键定义为 $Q = W F$ 和 $K = W F$ ，而第 i 个失真类型的特征的查询和键定义为 $Q = W F$ 和 $K = W E$ 。此外，值向量计算为 $V = W \text{Cat}([F, F])$ 。使用这些，差异细化注意力机制按如下方式提取第 i 个失真类型的图像特征：

$$F_{\text{失真}} = (\text{softmax}(QK) - \alpha \text{softmax}(QK))V \quad (2)$$

其中， $F_{\text{distortion}}$ 表示在第 i 种失真类型下的图像特征。 α 是一个可学习参数。因此，该模块能够隔离并细化专门对应于特定失真类型的特征。

随后，所有失真类型的特征被输入到一个由两个线性层组成的前馈网络 (FFN)，该网络使用 GELU 作为激活函数，从而生成用于识别不同失真特征的专家知识。

$$F = \text{FFN}(F_{\text{distortion}}, \dots, F_{\text{distortion}}), \quad (3)$$

其中， $\text{FFN}(\cdot)$ 是前馈网络。得益于差分细化注意力机制，该模块能够有效抑制冗余或重叠信息，准确提取与不同失真类型相关的特征，并通过 FFN 进一步整合和优化多失真特征，从而生成针对图像失真的专家级表示。

动态失真加权模块

为了根据图像失真对感知图像质量的影响分配失真权重，从而实现更可靠的图像质量评估分数，我们提出了一种混合专家系统，命名为动态失真加权模块 (DDWM)。该模块首先利用图像编码器提取的语义特征 F ，以及由 DSDM 使用可学习参数 λ 精细化的失真先验 $F = (1 - \lambda) \cdot F_{\text{distortion}}$ ，以平衡对后续建模的贡献。此外，名为 $F_{\text{bridging}} = F - F_{\text{are}}$ 的补充区间特征被进一步整合到该模块中，形成用于多维质量评估的全面特征组 $F = \text{Cat}([F_{\text{distortion}}, F, F])$ 。补充区间特征用于桥接特征维度或级别之间的分布差异，确保更连贯的表示。

基于这一特征组，自适应加权生成 (WG) 模块动态计算每种失真类型对质量感知的影响重要性，即每种失真类型的动态专家权重。这一过程可以描述为：

$$W_{\text{失真}}, \dots, W_{\text{失真}} = \text{WG}(F). \quad (4)$$

这里，加权生成指的是一个多层感知器

MLP（多层感知机）使用 PReLU 作为激活函数。最后，计算出的权重通过与 ViT（视觉 Transformer）的类标记 T 通过线性变换得到的标记相结合，表示当前图像质量。分数权重用于优化和调整最终图像质量分数，可以表示为：

$$\text{分数} = \sum_{i=1}^{10} W_{\text{失真} T(5)} x_i^{10}$$

实验

基准数据集

我们评估了 DR.Experts 在五个真实场景下的 BIQA 数据集上的性能。BID（Ciancio 等人，2010 年）和 LIVEC（Ghadiyaram 和 Bovik，2015 年）数据集分别包含 590 和 1,162 张由摄影师使用移动设备拍摄的照片。KonIQ-10k（Hosu 等人，2020 年）包含 10,073 张从公开可用的多媒体资源中选出的照片。SPAQ（Fang 等人，2020 年）包括 11,125 张使用智能手机相机拍摄的照片，涵盖了多样内容和分辨率。LIVEFB（Ying 等人，2020 年），迄今为止最大的真实数据集，包含 39,810 张照片。

采用两种广泛使用的 BIQA 指标作为性能评估指标，包括 Spearman 等级相关系数（SRCC）和 Pearson 线性相关系数（PLCC），以衡量 DR.Experts 的有效性。SRCC 评估预测分数与真实分数之间的单调关系，而 PLCC 反映模型的预测精度。这两个指标的取值范围从 0 到 1，数值越高表示性能越好。理想情况下，接近 1 的值表明具有更好的预测单调性和准确性。

实现细节

对于我们的方法，我们应用了 BIQA 中常用的标准数据增强技术，即将每张图像随机裁剪成较小的图像块。此外，我们遵循了 QPT（Zhao 等人，2023）和 QCN（Shin、Lee 和 Kim，2024）相同的实验设置。图像块的数量根据每个数据集的大小进行调整。我们方法中的图像编码器是 DeiTIII（Touvron、Cord 和 Jégou，2022）的小版本，在 ImageNet 上预训练，权重衰减为 0.05，批大小为 1024，训练了 400 个 epoch。至于先验知识模块，我们使用了预训练的 DA-CLIP 图像控制器和文本编码器（Luo 等人，2024）。该模块在训练过程中被冻结。

DR.Experts 然后在 BIQA 数据集上进行微调，共进行 9 个 epoch，同时冻结先验模块。学习率初始设置为 2×10^{-3} ，每 3 个 epoch 后降低 10 倍。模型训练采用 Smooth L1 损失函数，批大小根据数据集规模确定，例如 LIVEC 数据集为 64，KonIQ 数据集为 156。对于所有数据集，80% 的图像用于训练，剩余 20% 用于测试。我们重复进行 10 次这种训练-测试设置，以减少分割偏差。

并记录结果的中间值。我们使用 PyTorch 来实现 DR.Experts，所有实验均使用 4 块 RTX 4090 GPU 进行。

与 SOTA 方法的比较

在本实验中，涉及并比较了 14 种代表性的 BIQA 方法在自然场景数据集上的预测性能，包括 DR.Experts。其中，DIIVINE（Zhang, Zhang, and Bovik 2015）和 BRISQUE（Mittal, Moorthy, and Bovik 2012）基于手工感知特征，而其余方法基于学习架构，例如，DBCNN（Zhang et al. 2020）和 HyperIQA（Su et al. 2020）使用 CNN，而 MUSIQ（Ke et al. 2021）和 DEIQT（Qin et al. 2023）利用视觉 Transformer。此外，我们还包含了 TReS（Golestaneh, Dadsetan, and Kitani 2022）和 LODA（Xu et al. 2024），这些方法结合了 CNN 和 ViT 的优势，以及 LQMamba（Guan et al. 2025 年）基于视觉 Mamba 架构。如表 1 所示，DR.Experts 在五个包含各种复杂场景和失真程度的多样化 BIQA 数据集上表现出显著提升。考虑到这些数据集因其多样性而本质上具有挑战性，与 QFM-IQM（Li 等人，2024b）、LODA、LQMamba 和 QCN（Shin、Lee 和 Kim，2024）等 SOTA 方法相比，DR.Experts 在 KonIQ-10k 数据集上的 SRCC 和 PLCC 指标上分别至少提升了 0.75 和 0.95 个百分点。我们利用失真先验的设计进一步得到证实。此外，DR.Experts 优于利用质量预训练技术的其他方法，如 QPT（Zhao 等人，2023）和 CONRTIQUE（Madhusudana 等人，2022），进一步展示了其鲁棒性和适应性。这些结果有力地强调了 DR.Experts 在有效利用和精炼失真先验和特征方面的能力，特别是在具有挑战性的自然场景中。

泛化验证

我们进行了一项跨数据集的实验来验证模型的泛化能力，这是 BIQA 实践中的一个重要指标，其中模型在不同的数据集上进行训练和测试。结果如表 2 所示。简而言之，在所有不同的训练和测试对中，DR.Experts 在 SRCC 指标方面比之前的 SOTA 方法取得了更好的结果。这一结果也验证了利用失真先验知识来增强鲁棒性和泛化能力这一核心思想。

数据效率验证

得益于先验知识，以及通过 DSDM 进一步细化的质量感知注意力机制，我们的模型能够快速关注失真，从而减轻其对大规模数据的依赖。为了验证这一点，我们通过将训练集数据减少到原始大小的 60%、40%和 20%，同时保持相同的模型架构和训练设置，并与现有模型进行比较，进行了数据效率验证。如表 3 所示，在 60%模式下，DR.Experts 在 LIVEC 数据集上的表现比 LoDa 高出 2.3 和 3 个百分点。

	KonIQ LIVEC SPAQ LIVEFB BID											
方法	SRCC	PLCC	SRCC	PLCC	SRCC	PLCC	SRCC	PLCC	SRCC	PLCC	SRCC	PLCC
ILNIQE (Zhang, Zhang, and Bovik 2015)	0.503	0.496	0.453	0.511	0.719	0.654	0.219	0.255	0.495	0.454	BRISQUE (Mittal, Moorthy, and Bovik 2012)	0.715
0.702	0.601	0.621	0.802	0.806	0.320	0.356	0.574	0.540	WaDIQaM-NR (Bosse et al. 2017)	0.729	0.754	0.692
0.730	0.840	0.845	0.435	0.430	0.653	0.636	DB-CNN (Zhang et al. 2020)	0.878	0.887	0.844	0.862	0.910
0.913	0.554	0.652	0.845	0.850	HyperIQA (Su et al. 2020)	0.906	0.917	0.859	0.882	0.916	0.919	0.535
0.623	0.869	0.878	MUSIQ (Ke et al. 2021)	0.916	0.928	0.702	0.746	0.917	0.921	--	0.646	0.739
TReS (Golestaneh, Dadsetan, and Kitani 2022)	0.915	0.928	0.846	0.877	--	0.554	0.625	--	DEIQT (Qin et al. 2023)	0.921	0.934	0.875
0.894	0.919	0.923	0.571	0.663	--	CONRTIQUE(Madhusudana et al. 2022)	0.894	0.906	0.845	0.857	0.914	0.919
0.580	0.641	--	QPT(Zhao et al. 2023)	0.927	0.941	0.895	0.914	0.925	0.928	0.578	0.675	0.888
0.911	QCN (Shin, Lee, and Kim 2024)	0.934	0.945	0.875	0.893	0.923	0.928	--	0.892	0.890	QFM-IQM (Li et al. 2024b)	0.922
0.936	0.891	0.913	0.920	0.924	0.567	0.667	--	LODA (Xu et al. 2024)	0.932	0.944	0.876	0.899
0.925	0.928	0.578	0.679	--	LQMamba (Guan et al. 2025)	0.928	0.943	0.863	0.903	0.927	0.933	0.574
0.672	--											
DR.Experts (我们)	0.941	0.954	0.914	0.926	0.928	0.933	0.585	0.690	0.896	0.919		

在 LIVEC 数据集上，根据表 1 中通过 SRCC 和 PLCC 中位数测量的性能比较，我们的 DR.Experts 比 LoDa 高了 3 个和 3 个点，粗体条目表示前两名。训练集标注有*。

训练 LIVEFB LIVEC KonIQ							
测试 KonIQ LIVEC KonIQ LIVEC							
DBCNN	0.716	0.724	0.754	0.755	P2P-BM	0.755	0.738
0.740	0.770	HperIQA	0.758	0.735	0.772	0.785	TReS
0.713	0.740	0.733	0.786	DEIQT	0.733	0.781	0.744
0.794	LODA	0.763	0.805	0.745	0.811		
DR.Experts	0.783	0.807	0.785	0.841	增益	0.020(↑)	0.002(↑)
0.040(↑)	0.030(↑)						

表 2：泛化验证的 SRCC。最佳性能以粗体突出显示。增益是相对于次优性能计算的。

SRCC 和 PLCC 指标，分别。值得注意的是，在 20% 模式下，DR.Experts 对其他方法实现了最大的性能提升。这些结果进一步证实了 DR.Experts 良好的鲁棒性和泛化能力及其先验和精炼的核心思想。

消融研究

模块研究 我们进行了消融实验来评估所提出的失真显著性差分模块和动态失真加权模块的有效性。如表 4 所示，Image Encoder 代表仅使用 ViT 作为 BIQA 主干时的性能，结果表明质量评估的高级信息不足，从而导致数据稀缺，因为模型在较小的数据集 LIVEC 上的性能与大型数据集的可比性较低。DA-CLIP 指仅涉及先验模块的方法，其中视觉和语言编码器被冻结，然后进行与 CLIP-IQA 相同的点积操作以获得特定于失真的特征。

	KonIQ LIVEC 模式方法	SRCC	PLCC	SRCC	PLCC
20%	HyperNet	0.869	0.873	0.776	0.809
	DEIQT	0.888	0.908	0.792	0.822
	LoDa	0.907	0.923	0.815	0.854
	DR.Experts	0.917	0.931	0.837	0.861
40%	HyperNet	0.892	0.908	0.832	0.849
	DEIQT	0.903	0.922	0.838	0.855
	LoDa	0.922	0.935	0.849	0.879
	DR.Experts	0.929	0.942	0.874	0.896
60%	HyperNet	0.901	0.914	0.843	0.862
	DEIQT	0.914	0.931	0.848	0.877
	LoDa	0.928	0.940	0.869	0.891
	DR.Experts	0.939	0.950	0.899	0.914

表 3：使用包含 20%、40%和 60%图像的训练集进行数据高效学习验证。粗体条目表示最佳性能。

我们仅使用这些特征来训练预测头进行分数回归。结果表明，DA-CLIP 提取的特征不直接适用于 BIQA，因为某些失真类型（例如雨滴和未完成的）要么与视觉质量无关，要么有害。这些结果也与 CLIP-IQA 中的观察结果大体一致。基于这些特征，引入了 DSDM 来改进先验并净化注意力，从而减轻 BIQA 中的噪声干扰并提高最终性能，尤其是在较小的数据集上。此外，DR.Experts 意味着包含了所提出的 DDWM 模块，该模块利用全面的特征组来区分和优化各种失真（即级别和类型）对质量分数的贡献，进一步提高了 KonIQ 和 LIVEC 数据集上的指标。




图 3：DA-CLIP、图像编码器和 DSDM 输出的注意力图比较。

KonIQ LIVEC					
方法	SRCC	PLCC	SRCC	PLCC	
图像编码器	0.916	0.929	0.857	0.884	DA-CLIP 0.720
	0.754	0.587	0.635	DSDM 0.930	0.941 0.885 0.904
DR.Experts	0.941	0.954	0.914	0.926	

表 4：在 LIVEC 和 KonIQ 数据集上的消融实验。粗体项表示最佳性能。

特征组研究 表 5 比较了 DDWM 中特征组的不同组合。具体来说，Dis、Sem 和 Bri 分别代表由 DSDM 精炼的失真特征、图像编码器提取的语义特征以及从前两者特征组差异中推导出的辅助桥接特征。值得注意的是，Only 表示仅包含特定特征组，而 w/o 表示包含其他两个特征组但排除当前特征组。结果表明，随着引入更多特征组，所提出的方法包含更多信息，导致更全面的权衡，更好地反映当前图像的质量得分。

定性分析图 3 展示了一种比较分析，涉及三种类型的注意力图：从 DA-CLIP 获得的针对特定失真的注意力图、图像编码器产生的语义注意力图以及通过 DSDM 对失真进行优化的注意力图。技术上，我们仅可视化了 DDWM 识别出的对图像质量影响最显著的三个失真。从图中可以看出，优化的注意力图有效地抑制了与语义信息相关的无关区域，同时减轻了由虚假引入的注意力噪声。

KonIQ LIVEC					
方法	SRCC	PLCC	SRCC	PLCC	
仅 Dis	0.933	0.944	0.897	0.912	仅 Sem 0.936
	0.944	0.899	0.913	仅 Bri 0.936	0.947 0.897
	0.914				
w/o Dis	0.938	0.948	0.913	0.918	w/o Sem
	0.940	0.951	0.911	0.919	w/o Bri 0.939 0.950
	0.909	0.916			
Full(Ours)	0.941	0.954	0.914	0.926	

表 5：不同特征组组合的消融研究。粗体项表示最佳性能。失真。这些结果表明，所提出的 DSDM 显著增强了在 BIQA 任务中捕获和细化重要失真特征的能力。

结论

我们提出了 DR.Experts，一个利用失真先验知识改进的失真感知视觉语言模型来提升的盲图像质量评估框架。其动态失真加权模块通过失真特征和语义等线索自适应地加权特征，以模拟人类视觉。这种设计减少了过度依赖统一特征，并提高了数据效率。大量实验验证了 DR.Experts 在盲图像质量评估基准测试中的优越性能和泛化能力。

致谢

这项工作部分得到了中国自然科学基金（项目编号：62301041）和北京理工大学青年学者研究基金项目的支持。

参考文献

- Agnolucci, L.; Galteri, L.; 和 Bertini, M. 2024. 基于质量感知的图像-文本对齐用于无观点感知的图像质量评估. arXiv 预印本 arXiv:2403.11176.
- Agnolucci, L.; Galteri, L.; Bertini, M.; 和 Del Bimbo, A. 2024a. Arniqa: 学习图像质量评估的失真流形. 在 IEEE/CVF 冬季计算机视觉应用会议论文集, 189–198.
- Agnolucci, L.; Galteri, L.; Bertini, M.; 和 Del Bimbo, A. 2024b. 基于参考的数字化模拟录像带修复. 在 IEEE/CVF 冬季计算机视觉应用会议论文集, 1659–1668.
- Bosse, S.; Maniry, D.; Müller, K.-R.; Wiegand, T.; 和 Samek, W. 2017. 深度神经网络用于无参考和全参考图像质量评估. IEEE 图像处理汇刊, 27(1): 206–219.
- Chen, C.; Mo, J.; Hou, J.; Wu, H.; Liao, L.; Sun, W.; Yan, Q.; 和 Lin, W. 2024. Topiq: 从语义到失真的自上而下方法用于图像质量评估. IEEE 图像处理汇刊, 33: 2404–2418.
- Chu, X.; Duan, H.; Wen, Z.; Xu, L.; Hu, R.; 和 Xiang, W. 2025a. 联合域知识蒸馏用于水声目标识别. IEEE 地球科学与遥感学报.
- Chu, X.; Zhou, H.; Zhang, Y.; Zhang, Y.; Hu, R.; Duan, H.; Huang, Y.; Zheng, Y.; 和 Ji, R. 2025b. 注意力驱动的声学特性学习用于水声目标测距.
- 模式识别, 164: 111560.
- Ciancio, A.; Da Silva, E. A.; Said, A.; Samadani, R.; Obrador, P.; 等. 2010. 基于多特征分类器的数字图像无参考模糊评估. IEEE 图像处理学报, 20(1): 64–75.
- 邓静; 董伟; Socher, R; 李立杰; 李科; 以及 FeiFei, L. 2009. Imagenet: 一个大规模的层次化图像数据库. 在 2009 年 IEEE 计算机视觉与模式识别会议, 248–255.
- Lee, D.; Dosovitskiy, A.; Beyer, L.; Kolesnikov, A.; Weissenborn, D.; Zhai, X.; Unterthiner, T.; Dehghani, M.; Minderer, M.; Heigold, G.; Gelly, S.; 等. 2020. 一张图值 16x16 个词: 用于大规模图像识别的 Transformer. 在 International Conference on Learning Representations.
- Fang, Y.; Zhu, H.; Zeng, Y.; Ma, K.; 以及 Wang, Z. 2020. 智能手机摄影感知质量评估. 在 Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 3677–3686.
- Ghadiyaram, D.; 以及 Bovik, A. C. 2015. 大规模在线众包的主观和客观图像质量研究. IEEE transactions on image processing, 25(1): 372–387.
- Golestaneh, S. A.; Dadsetan, S.; 以及 Kitani, K. M. 2022. 基于 Transformer、相对排序和自一致性的无参考图像质量评估. 在 Proceedings of the IEEE/CVF winter conference on applications of computer vision, 1220–1230.
- Guan, F.; Li, X.; Yu, Z.; Lu, Y.; 和 Chen, Z. 2025. QMamba: 视觉 Mamba 在图像质量评估中的首次探索. 在第 42 届国际机器学习会议.
- He, K.; Zhang, X.; Ren, S.; 和 Sun, J. 2016. 深度残差学习用于图像识别. 在 IEEE 计算机视觉与模式识别会议论文集, 770–778.
- Hosu, V.; Lin, H.; Sziranyi, T.; 和 Saupe, D. 2020. KonIQ10k: 用于盲图像质量评估深度学习的生态有效数据库. IEEE 图像处理汇刊, 29: 4041–4056.
- Hu, R.; Chu, X.; Dou, D.; Liu, X.; Liu, Y.; 和 Qi, B. 2025. 迈向实际应用: 通过知识蒸馏实现轻量级水下声学定位模型. IEEE 海洋工程汇刊.
- 黄铮; 李翔; 付博; 褚翔; 李凯; 沈阳; 张宇. 2024. 选择性注意力机制的尺度对比学习用于盲图像质量评估. arXiv 预印本 arXiv:2411.09007.
- 康磊; 叶培; 李岩; 以及多默尔. 2014. 卷积神经网络用于无参考图像质量评估. 在 IEEE 计算机视觉与模式识别会议论文集中, 1733–1740.
- 柯建; 王启; 王宇; 米兰法尔; 以及杨帆. 2021. Musiq: 多尺度图像质量变换器. 在 IEEE/CVF 国际计算机视觉会议论文集中, 5148–5157.
- 权东; 金东; 基锡; 赵毅; 李惠恩; 以及金世俊. 2024. ATTIQA: 使用属性感知预训练的通用图像质量特征提取器. 在亚洲计算机视觉会议论文集中, 4526–4543.
- Li, A.; Wu, J.; Liu, Y.; 和 Li, L. 2024a. 桥接合成到真实的差距: 基于失真的无监督域适应用于盲图像质量评估. 在 IEEE/CVF 计算机视觉与模式识别会议论文集, 28422–28431.
- Li, J.; Li, D.; Savarese, S.; 和 Hoi, S. 2023. Blip-2: 冻结图像编码器和大型语言模型的引导语言-图像预训练. 在国际机器学习会议, 19730–19742. PMLR.
- Li, X.; Gao, T.; Hu, R.; Zhang, Y.; Zhang, S.; Zheng, X.; Zheng, J.; Shen, Y.; Li, K.; Liu, Y.; 等. 2024b. 通过减轻语义噪声敏感性进行无参考图像质量评估的自适应特征选择. 在国际机器学习会议, 27808–27821. PMLR.
- Li, X.; Huang, Z.; Zhang, Y.; Shen, Y.; Li, K.; Zheng, X.; Cao, L.; 和 Ji, R. 2025. 少样本图像质量评估通过视觉语言模型的适配. 在 IEEE/CVF 国际计算机视觉会议论文集, 10442–10452.
- Liang, Z.; Li, C.; Zhou, S.; Feng, R.; 和 Loy, C. C. 2023. 迭代提示学习用于无监督逆光图像增强. 在 IEEE/CVF 国际计算机视觉会议论文集, 8094–8103.
- Luo, Z.; Gustafsson, F. K.; Zhao, Z.; Sjöstrand, J.; 和 Schöon, T. B. 2024. 控制视觉语言模型进行多任务图像修复. 在国际学习表示会议.

- Madhusudana, P.; Birkbeck, N.; Wang, Y.; Adsumilli, B.; 和 Bovik, A. 2022. 基于对比学习的图像质量评估. IEEE 图像处理汇刊: IEEE 信号处理学会出版物, 31: 4149–4161.
- Mittal, A.; Moorthy, A. K.; and Bovik, A. C. 2012. 空间域无参考图像质量评估. IEEE 图像处理汇刊, 21(12): 4695–4708.
- Moorthy, A. K.; and Bovik, A. C. 2011. 盲图像质量评估: 从自然场景统计到感知质量. IEEE 图像处理汇刊, 20(12): 3350–3364.
- Qin, G.; Hu, R.; Liu, Y.; Zheng, X.; Liu, H.; Li, X.; and Zhang, Y. 2023. 基于注意力面板解码器的数据高效图像质量评估. AAAI 人工智能会议论文集, 第 37 卷, 2091–2100.
- Qin, G.; Wang, Z.; Shen, D.; Liu, H.; Zhou, H.; Wu, J.; Hu, R.; and Jin, Y. 2025. 结构很重要: 重新审视视频对象分割中的边界细化. IEEE/CVF 国际计算机视觉会议论文集 (ICCV), 14431–14442.
- Radford, A.; Kim, J. W.; Hallacy, C.; Ramesh, A.; Goh, G.; Agarwal, S.; Sastry, G.; Askell, A.; Mishkin, P.; Clark, J.; et al. 2021. 从自然语言监督中学习可迁移的视觉模型. 在机器学习国际会议, 8748–8763. PmLR.
- Saad, M. A.; Bovik, A. C.; and Charrier, C. 2012. 盲图像质量评估: DCT 域中的自然场景统计方法. IEEE 图像处理汇刊, 21(8): 3339–3352.
- Saha, A.; Mishra, S.; and Bovik, A. C. 2023. Re-iqa: 野外图像质量评估的无监督学习. 在 IEEE/CVF 计算机视觉与模式识别会议论文集, 5846–5855.
- Shin, N.-H.; Lee, S.-H.; and Kim, C.-S. 2024. 基于几何顺序学习的盲图像质量评估. 在 IEEE/CVF 计算机视觉与模式识别会议论文集, 12799–12808.
- 苏珊, 杨倩, 朱宇, 张超, 葛晓, 孙杰, 张阳. 2020. 基于自适应超网络的野外图像质量盲评估. IEEE/CVF 计算机视觉与模式识别会议论文集, 3667–3676.
- 托夫龙, 科德, 杰古. 2022. Deit iii: Vit 的复仇. 欧洲计算机视觉会议, 516–533. 斯普林格.
- 王杰, 陈凯, 刘畅. 2023. 探索 Clip 评估图像外观和感觉. AAAI 人工智能会议论文集, 第 37 卷, 2555–2563.
- 王杰, 陈鹏, 郑宁, 陈波, 普林西普, 王飞燕. 2021. MSE 和 SSIM 作为线性分解中成本函数的关联性及其在稀疏编码比特分配中的应用. 神经计算, 422: 139–149.
- 吴, H.; 张, Z.; 张, W.; 陈, C.; 廖, L.; 李, C.; 高, Y.; 王, A.; 张, E.; 孙, W.; 等. 2024a. Q-Align: 通过离散文本定义级别教授 LMM 进行视觉评分. 在国际机器学习会议, 54015–54029. PMLR.
- 吴, H.; 朱, H.; 张, Z.; 张, E.; 陈, C.; 廖, L.; 李, C.; 王, A.; 孙, W.; 严, Q.; 等. 2024b. 开放式视觉质量比较. 在欧洲计算机视觉会议, 360–377. Springer.
- 徐, K.; 廖, L.; 肖家, J.; 陈, C.; 吴, H.; 严, Q.; 和 林, W. 2023. 局部失真感知高效 Transformer 适应于图像质量评估. CoRR.
- 徐, K.; 廖, L.; 肖家, J.; 陈, C.; 吴, H.; 严, Q.; 和 林, W. 2024. 通过局部特征增强的高效 Transformer 适应提升图像质量评估. 在 IEEE/CVF 计算机视觉与模式识别会议论文集, 2662–2672.
- 杨洁; 付俊; 张铮; 刘磊; 李奇; 张伟; 曹伟. 2024. Align-IQA: 通过可定制指导对齐具有多样化人类偏好的图像质量评估模型. 在 ACM 国际多媒体会议第 32 届论文集, 10008–10017.
- 叶涛; 董立; 夏雨; 孙阳; 朱宇; 黄刚; 魏峰. 2025. 差分 Transformer. 在第十三届国际学习表示会议.
- 英政; 牛辉; 古普塔, 帕特里夏; 马哈扬, 迪帕克; 加迪亚拉姆, 迪帕克; 鲍维克, 安德鲁. 2020. 从块到图像 (PaQ-2-PiQ): 映射图像质量感知空间. 在 IEEE/CVF 计算机视觉与模式识别会议论文集, 3575–3585.
- 张磊; 张立; 鲍维克, A.C.. 2015. 一种特征丰富的完全盲图像质量评估器. IEEE 图像处理汇刊, 24(8): 2579–2591.
- 张伟; 马凯; 严俊; 邓东; 王铮. 2020. 使用深度双线性卷积神经网络的盲图像质量评估. IEEE 电路与系统视频技术汇刊, 30(1): 36–47.
- 赵凯; 袁坤; 孙梦; 李明; 汪鑫. 2023. 基于质量感知的预训练模型用于盲图像质量评估. 在 IEEE/CVF 计算机视觉与模式识别会议论文集, 22302–22313.
- 周浩; 杨锐; 唐立; 秦刚; 胡瑞; 李翔. 2025. Gamma: 基于混合评估专家的通用图像评估方法. 在第 33 届 ACM 国际多媒体会议, MM ’ 25, 8815–8824. 纽约, 纽约, 美国: 计算机协会. ISBN 9798400720352.